SVGAP11-CXSV 清洁版中文使用手册

Yi Liao @ scau.edu.cn

2026-07-07

Contents

1 SVGAP11-CXSV 清洁版中文使用手册 **2**
1.1 1. 本次清理和修复内容 . . . 2
1.1.1 1.1 彻底解决 Parallel::ForkManager 警告 . . . 2
1.1.2 1.2 脚本作者信息 . . . 2
1.1.3 1.3 文件包清理 . . . 2
1.2 2. 清洁版包结构 . . . 3
1.3 3. 输入文件准备：ISO1 reference + A3/A4/A5 queries . . . 3
1.3.1 3.1 推荐目录 . . . 3
1.3.2 3.2 g.list 文件 . . . 3
1.3.3 3.3 genome FASTA 命名 . . . 4
1.3.4 3.4 AXT 命名 . . . 4
1.4 4. 一键运行主流程 . . . 4
1.4.1 4.1 推荐方式：从已有 AXT 开始 . . . 4
1.4.2 4.2 从 MAF 开始 . . . 5
1.4.3 4.3 从 aligner 原始输出开始 . . . 5
1.4.4 4.4 使用真正 reciprocal alignment . . . 5
1.5 5. 主流程输出目录解释 . . . 5
1.6 6. 流程步骤详细说明 . . . 6
1.6.1 Step 01：01_Convert2Axt.pl . . . 6
1.6.2 Step 02：02_ChainNetSyn.pl . . . 7
1.6.3 Step 03：03_SynNetFilter.pl . . . 7
1.6.4 Step 04：04_PairwiseSV.pl . . . 8
1.6.5 Step 05：05_CombineSV.pl . . . 9
1.6.6 Step 06：06_genotype_DEL.pl . . . 10
1.6.7 Step 07：07_genotype_INS.pl . . . 10
1.6.8 Step 08：08_genotype_small_indels.pl . . . 11
1.6.9 Step 09：09_SNPgenotyping.pl . . . 12
1.6.10 Step 10：10_SVannotation.pl . . . 12
1.6.11 Step 11：11_INVgenotyping.pl . . . 13
1.6.12 Step 12：12_combine_genotype_CXSV.pl . . . 14
1.6.13 SVGAP_pipeline.pl 主控脚本参数 . . . 15
1.6.14 SVGAP_vcf_tools.pl . . . 16
1.7 7. 结果检查建议 . . . 16
1.8 8. 常见问题 . . . 16
1.8.1 8.1 仍然出现 Parallel::ForkManager warning . . . 16
1.8.2 8.2 AXT 文件找不到 . . . 17
1.8.3 8.3 genome FASTA 找不到 . . . 17
1.8.4 8.4 minimap2 缺失 . . . 17
1.8.5 8.5 内存和线程 . . . 17
1.8.6 8.6 qnet 和 reciprocal 怎么选 . . . 17
1.9 9. 培训演示建议流程 . . . 17

1 SVGAP11-CXSV 清洁版中文使用手册

作者标注：本包中每个 Perl 脚本均已加入 `Author: Yi Liao @ scau.edu.cn`。
适用场景：以一个参考基因组和多个 query 基因组为输入，完成 assembly-to-assembly 的 SV、复杂 SV、SNP 和 small InDel 检测、合并、genotyping 与可选注释。
示例数据设定：`ISO1` 为 reference，`A3`、`A4`、`A5` 为 query genomes。

1.1 1. 本次清理和修复内容

1.1.1 1.1 彻底解决 Parallel::ForkManager 警告

你之前反复遇到的警告是：

```
WARNING: Parallel::ForkManager is not installed; falling back to single-thread mode
```

这不是因为包里完全没有 `Parallel::ForkManager`。实际情况是：这个包中已经带有：

```
lib/Parallel/ForkManager.pm
```

以及其依赖模块。但是部分脚本运行时没有稳定地把包内 `lib/` 加入 Perl 的 `@INC` 搜索路径，所以 `require Parallel::ForkManager` 会失败，脚本就回退到单线程。

现在所有 `.pl` 脚本都统一加入了类似下面的路径设置：

```
use FindBin qw($Bin);
use lib "$Bin/lib";
use lib "$Bin/pub";
use lib "$Bin/../lib";
use lib "$Bin/../pub";
use lib "$Bin/../../lib";
use lib "$Bin/../../pub";
```

因此，主目录脚本、`util/` 下脚本、`trash/` 下保留脚本都可以优先调用包内 Perl 模块。正常情况下不再需要用户手动安装 `Parallel::ForkManager`，也不应再回退到单线程。

可用下面的命令快速检查：

```
cd SVGAP11_clean_fixed
perl -Ilib -MParallel::ForkManager -e 'print "Parallel::ForkManager OK\n"'
```

1.1.2 1.2 脚本作者信息

每个 Perl 脚本头部均加入：

```
# Author: Yi Liao @ scau.edu.cn
```

1.1.3 1.3 文件包清理

为保持生产流程简洁，下面文件没有删除，而是移动到 `trash/`：

```
trash/benchmark_tools/
  simulate_population_variants_benchmark_shared.v4.pl
  13_compare_truth_SVGAP.pl
  14_diagnose_small_indel_benchmark.pl

trash/integration_notes/
  SVGAP_pipeline.add_12_CXSV.patch
  README_CXSV_integration.txt

trash/legacy_utilities/
  FaFileChecl.pl
  INS2TDP.pl
```

```
  Mafreformat.pl
  SplitFa.pl
```

这些文件不是正式运行 ISO1/A3/A4/A5 流程所必需的。如果后续要做模拟 benchmark 或恢复旧工具，可以从 trash/ 取回。

1.2 2. 清洁版包结构

```
SVGAP11_clean_fixed/
  SVGAP_pipeline.pl                # 主控脚本，一键运行全流程
  01_Convert2Axt.pl                # Step 01: alignment 转 AXT
  02_ChainNetSyn.pl                # Step 02: AXT -> chain/net/synnet
  03_SynNetFilter.pl               # Step 03: synnet 过滤 + single-coverage MAF
  04_PairwiseSV.pl                 # Step 04: pairwise SV calling
  05_CombineSV.pl                  # Step 05: SV 合并
  06_genotype_DEL.pl               # Step 06: deletion genotyping
  07_genotype_INS.pl               # Step 07: insertion genotyping
  08_genotype_small_indels.pl      # Step 08: small InDel genotyping
  09_SNPgenotyping.pl              # Step 09: SNP genotyping
  10_SVannotation.pl               # Step 10: SV annotation
  11_INVgenotyping.pl              # Step 11: inversion genotyping
  12_combine_genotype_CXSV.pl      # Step 12: complex SV 合并和 genotyping
  SVGAP_vcf_tools.pl               # VCF 合并/样本顺序整理工具
  lib/                             # Perl 模块依赖，包括 Parallel::ForkManager
  pub/                             # UCSC/TBA/MUMMER/Stretcher 等工具或辅助脚本
  util/Test_dependency.pl          # 依赖测试脚本
  docs/                            # 本手册
  trash/                           # 非生产流程必需文件的归档目录
```

1.3 3. 输入文件准备：ISO1 reference + A3/A4/A5 queries

1.3.1 3.1 推荐目录

```
project/
  SVGAP11_clean_fixed/
  genomes/
    ISO1.fa
    A3.fa
    A4.fa
    A5.fa
  g.list
  01_axt/Target/                 # 如果从 AXT 开始
    ISO1vsA3.axt
    ISO1vsA4.axt
    ISO1vsA5.axt
```

1.3.2 3.2 g.list 文件

g.list 中每行一个 genome ID。reference 也要写进去，主流程会自动把 reference 从 VCF 样本列中排除。因此最终 VCF 样本顺序为 A3，A4，A5。

```
ISO1
A3
A4
A5
```

1.3.3 3.3 genome FASTA 命名

每个 ID 可以对应以下任一文件名：

```
ID
ID.fa
ID.fasta
ID.fna
```

在本例中推荐使用：

```
genomes/ISO1.fa
genomes/A3.fa
genomes/A4.fa
genomes/A5.fa
```

FASTA header 推荐带样本前缀，便于后续结果解释：

```
>ISO1.Chr01
>A3.Chr01
>A4.Chr01
>A5.Chr01
```

不建议 header 以数字开头。

1.3.4 3.4 AXT 命名

如果直接从 AXT 开始，forward AXT 文件名必须是：

```
ISO1vsA3.axt
ISO1vsA4.axt
ISO1vsA5.axt
```

如果有真正独立生成的 reciprocal alignment，可以准备：

```
A3vsISO1.axt
A4vsISO1.axt
A5vsISO1.axt
```

注意：不要简单反转 forward AXT 来伪造 reciprocal AXT。那只是坐标重排，不是真正的 query-vs-reference alignment。

1.4 4. 一键运行主流程

1.4.1 4.1 推荐方式：从已有 AXT 开始

如果你已经有 `ISO1vsA3.axt`、`ISO1vsA4.axt`、`ISO1vsA5.axt`，建议这样运行：

```
cd project/SVGAP11_clean_fixed

perl SVGAP_pipeline.pl \
  --refname ISO1 \
  --glist ../g.list \
  --genome_dir ../genomes \
  --start_from axt \
  --axt_dir ../01_axt/Target \
  --outdir ../SVGAP_run \
  --threads 12 \
  --speciesname ISO1_A3_A4_A5 \
  --skip_annotation
```

这里加 `--skip_annotation` 是因为注释步骤需要 TE/CDS 输入或 minimap2 环境。第一次培训演示时建议先跳过 annotation，确保主体检测流程完成。

1.4.2 4.2 从 MAF 开始

如果已有 forward MAF，文件名推荐为：

```
ISO1vsA3.maf
ISO1vsA4.maf
ISO1vsA5.maf
```

运行：

```
perl SVGAP_pipeline.pl \
  --refname ISO1 \
  --glist ../g.list \
  --genome_dir ../genomes \
  --start_from maf \
  --maf_dir ../MAF_forward \
  --outdir ../SVGAP_run_from_maf \
  --threads 12 \
  --speciesname ISO1_A3_A4_A5 \
  --skip_annotation
```

1.4.3 4.3 从 aligner 原始输出开始

如果从 minimap2/LAST/LASTZ/MUMmer/AnchorWave 的输出开始，由 `01_Convert2Axt.pl` 统一转换为 AXT。

```
perl SVGAP_pipeline.pl \
  --refname ISO1 \
  --glist ../g.list \
  --genome_dir ../genomes \
  --start_from align \
  --aligner minimap2 \
  --align_dir ../alignments \
  --outdir ../SVGAP_run_from_align \
  --threads 12 \
  --speciesname ISO1_A3_A4_A5 \
  --skip_annotation
```

1.4.4 4.4 使用真正 reciprocal alignment

如果你独立运行了 query-vs-reference alignment，可用：

```
perl SVGAP_pipeline.pl \
  --refname ISO1 \
  --glist ../g.list \
  --genome_dir ../genomes \
  --start_from axt \
  --axt_forward_dir ../AXT_forward \
  --axt_reciprocal_dir ../AXT_query_vs_ref_independent \
  --reciprocal_strategy true \
  --outdir ../SVGAP_run_true_reciprocal \
  --threads 12 \
  --speciesname ISO1_A3_A4_A5 \
  --skip_annotation
```

如果没有 reciprocal alignment，默认使用 `qnet` 策略即可。

1.5 5. 主流程输出目录解释

主控脚本会在 `--outdir` 中生成：

```
SVGAP_run/
  01_axt/                          # AXT 准备或转换结果
  02_chain_forward/                # forward chain/net/synnet
  02_chain_independent_reciprocal/ # 可选 reciprocal chain/net/synnet
  03_filter_forward/               # filtered synnet + single-coverage MAF
  03_filter_independent_reciprocal/
  04_pairwise_inputs/              # PairwiseSV 输入 synnet 子集
  04_pairwise_sv/                  # 每个 pair 的 raw SV
  05_combined_sv/                  # 合并后的 DEL/INS/INV/CNV/TRL 候选
  06_genotype/                     # DEL/INS/small InDel/INV/CXSV genotyping
  07_snp/                          # SNP calling/genotyping
  08_vcf/                          # 最终 VCF 输出
  09_annotation/                   # 可选 annotation 工作目录
  SVGAP_pipeline.log               # 主流程日志
```

最重要的最终文件通常在:

```
SVGAP_run/08_vcf/All.largeSV.raw.vcf
SVGAP_run/08_vcf/All.largeSV.annotated.vcf     # 如果 annotation 开启
SVGAP_run/08_vcf/All.smallIndel.vcf
SVGAP_run/08_vcf/All.sorted.SNP.vcf
SVGAP_run/08_vcf/All.CXSV.vcf
```

1.6 6. 流程步骤详细说明

1.6.1 Step 01：01_Convert2Axt.pl

功能：把 LAST、LASTZ、MUMmer、minimap2、AnchorWave 或已有 MAF 转换为 AXT。也可把 query FASTA 切分为 overlapping subcontigs，并把 split contig 坐标恢复到原始 chromosome 坐标。

常用命令:

```
perl 01_Convert2Axt.pl \
  --ali minimap2 \
  --input ../alignments \
  --wk ../01_axt \
  --tname ISO1 \
  --qname A3 \
  --t 8
```

主要参数:

参数	说明
`--ali`	输入 alignment 类型：`last`、`lastz`、`maf`、`mummer`、`minimap2`、`anchorwave`。
`--input`	alignment 文件所在目录。
`--wk`	工作目录/输出目录。
`--tname`	target/reference 名称，默认 `Ref`。
`--qname`	query 名称，默认 `Que`。
`--mode` / `--coord`	`auto`、`chr` 或 `ctg`。`ctg` 用于 split query subcontig 坐标恢复。
`--t` / `--threads`	并行进程数，默认 4。现在会自动使用包内 `Parallel::ForkManager`。
`--query`	同时生成 query-as-reference AXT。
`--keep_tmp`	保留中间文件。
`--mum320`	MUMmer `delta2maf` 所在目录或路径。
`--ucsc`	UCSC 工具目录，例如 `mafToAxt`。
`--tba`	TBA 工具目录。
`--k8`	`k8` 路径，用于 paftools。

参数	说明
--paftools	paftools.js 路径。
--splitfa / --fasta	需要切分的 FASTA，可重复使用。
--bin	split 主窗口大小，默认 10,000,000 bp。
--slide	split 窗口重叠大小，默认 10,000 bp。
--split_out	split FASTA 输出目录。
--sizes / --qsize / --size	原始 chromosome size 文件，用于 ctg 模式坐标恢复。

1.6.2 Step 02：02_ChainNetSyn.pl

功能：从 AXT 构建 UCSC chain/net/syntenic-net，并可生成 target-oriented single-coverage MAF。

常用命令：

```
perl 02_ChainNetSyn.pl \
  --gd ../genomes \
  --ad ../01_axt/Target \
  --lst ../g.list \
  --outdir ../SVGAP_run/02_chain_forward \
  --threads 12 \
  --sing
```

主要参数：

参数	说明
--gd	genome FASTA 目录。脚本会寻找 ID、ID.fa、ID.fasta、ID.fna。
--ad	AXT 文件目录，文件名必须类似 TargetIDvsQueryID.axt。
--lst	genome ID list。
--outdir / --syn	输出目录。
--ucsc	UCSC 工具目录。
--tba	TBA 工具目录。
--linearGap / --lg	chainNet linearGap 文件，默认 pub/TBA/medium。
--minscore / --minScore	axtChain/chainNet 最低分数，默认 1000。
--minSpace	chainNet minSpace，默认 1。
--t / --threads	并行任务数，默认 1。
--sing	生成 single-coverage MAF。
--keep_raw_chain	保留 raw chain 文件。
--keep_temp	保留临时 AXT/MAF 文件。
--force	覆盖已有结果。
--dry_run	只打印命令，不真正执行。

主要输出：

```
chain/*.chain.filter
net/*.tnet, *.qnet
synnet/*.tnet.synnet, *.qnet.synnet
singRaw/*.sing.maf
```

1.6.3 Step 03：03_SynNetFilter.pl

功能：过滤 synnet 中不可靠的短 fill，生成更保守的 CleanSynNet、RawSV gap 文件和 filtered single-coverage MAF。

常用命令：

```
perl 03_SynNetFilter.pl \
  --synnet ../SVGAP_run/02_chain_forward/synnet \
  --chain ../SVGAP_run/02_chain_forward/chain \
  --gd ../genomes \
  --outdir ../SVGAP_run/03_filter_forward \
  --threads 12
```

主要参数:

参数	说明
`--synnet`	Step 02 生成的 synnet 目录。
`--chain`	Step 02 生成的 chain 目录。
`--gd`	genome FASTA/.sizes/.2bit 目录。
`--outdir`	输出目录。
`--ucsc`	UCSC 工具目录。
`--tba`	TBA 工具目录。
`--cleanSynnet`	CleanSynNet 输出子目录名，默认 `CleanSynNet`。
`--sing`	filtered single MAF 输出子目录名，默认 `filtered_sing`。
`--axt`	cleaned synnet 转 AXT 的输出子目录名。
`--homopairs`	homologous pair summary 输出子目录名。
`--rawsv`	raw SV gap 输出子目录名。
`--target` / `--refname`	只处理指定 target/reference。
`--query`	只处理指定 query。
`--toplen`	top syntenic fill 最小长度，默认 500000。
`--nonsynlen`	下层 nonSyn fill 最小长度，默认 500000。
`--synlen`	下层 syn fill 最小长度，默认 500000。
`--invlen`	inversion fill 最小长度，默认 10000。
`--alrate`	最小 alignment/fill length 比例，默认 0.10。
`--qFarCutoff`	inversion fill 的最大 qFar，默认 5000000。
`--minscore`	最低分数阈值。
`--t` / `--threads`	并行任务数。
`--sing_only_tnet`	只从 tnet 生成 single MAF。
`--keep_temp`	保留临时文件。
`--force`	覆盖已有输出。
`--dry_run`	只打印命令。

1.6.4 Step 04：04_PairwiseSV.pl

功能：从 cleaned synnet 直接识别 pairwise SV，包括 DEL、INS、CNV、INV、TRL 和复杂 PAV/CMPLX 事件。新版使用 Perl 内置 `fork()/waitpid()`，不依赖 `Parallel::ForkManager`。

常用命令:

```
perl 04_PairwiseSV.pl \
  --syndir ../SVGAP_run/03_filter_forward/CleanSynNet \
  --outdir ../SVGAP_run/04_pairwise_sv \
  --gd ../genomes \
  --threads 12 \
  --seq
```

主要参数:

参数	说明
`--synnet` / `--syn`	单个 cleaned synnet 文件。
`--syndir`	cleaned synnet 文件目录，适合批量运行。
`--outdir`	输出目录。
`--gd`	genome FASTA 目录。

参数	说明
--ref_fa	reference FASTA，单文件运行时可显式指定。
--qry_fa / --query_fa	query FASTA。
--seq	在输出中写入 REF/ALT 序列。
--exact_seq_len	尽量输出完整序列。
--t / --threads	并行任务数。
--invlen	INV 最小长度。
--cnvlen	CNV 最小长度。
--dellen	DEL 最小长度。
--inslen	INS 最小长度。
--trllen	translocation/TRL 最小长度。
--filltoplen	top fill 长度阈值。
--fill2len	second-level fill 长度阈值。
--rate	alignment rate 阈值。
--max_level	synnet 解析最大层级。
--seq_context	输出序列时保留的 flank context。
--max_full_seq	完整输出序列的最大长度。
--edge_seq_len	长序列截断时两端保留长度。
--max_opposite_len	旧参数，保留兼容。
--max_opposite_ratio	DEL/INS 判定中另一侧 gap 最大比例，默认建议 0.10。
--keep_tmp	保留临时文件。
--quiet	减少屏幕输出。

1.6.5 Step 05：05_CombineSV.pl

功能：把多个 pairwise raw SV 合并为 population-level 候选事件，并按 SV 类型输出。

常用命令：

```
perl 05_CombineSV.pl \
  --sv ../SVGAP_run/04_pairwise_sv \
  --refname ISO1 \
  --outdir ../SVGAP_run/05_combined_sv \
  --sort_threads 12
```

主要参数：

参数	说明
--sv / --svdir / --pairsv	Step 04 raw SV 目录。
--refname	reference ID。
--outdir	输出目录。
--ins_tol	insertion 合并位置容忍度/比例。
--del_ov	deletion 合并最小 overlap。
--len_ratio	合并时允许的长度比例差异。
--cant / --candidate	最小候选支持数。
--min_large_len	large SV 最小长度。
--max_indel_len	small InDel 最大长度。
--legacy_indel	使用旧的 indel 输出逻辑。
--write_ins_reference	输出 reference insertion 表。
--cnv_ov	CNV 合并 overlap。
--cnv_len_ratio	CNV 长度比例阈值。
--cnv_bp_tol	CNV breakpoint 容忍 bp。
--inv_ov	INV 合并 overlap。
--inv_len_ratio	INV 长度比例阈值。
--inv_bp_tol	INV breakpoint 容忍 bp。

参数	说明
`--trl_ov`	TRL overlap 阈值。
`--trl_len_ratio`	TRL 长度比例阈值。
`--trl_bp_tol`	TRL breakpoint 容忍 bp。
`--trl_require_qchr`	TRL 合并时要求 query chromosome 匹配。
`--sort_mem`	sort 内存，例如 `2G`。
`--sort_threads`	sort 使用线程数。
`--sort_bin`	sort 程序路径。
`--keep_temp`	保留临时文件。
`--verbose`	输出更详细日志。

1.6.6 Step 06：06_genotype_DEL.pl

功能：基于 single-coverage MAF 对 merged deletions 进行 population genotyping，输出 matrix 和 VCF。

常用命令：

```
perl 06_genotype_DEL.pl \
  --bed ../SVGAP_run/05_combined_sv/All.DELs.50bplarge.bed.combined.sorted.txt \
  --maf_dir ../SVGAP_run/03_filter_forward/filtered_sing \
  --refname ISO1 \
  --query_list ../SVGAP_run/query.list \
  --out ../SVGAP_run/06_genotype/DEL.large \
  --threads 12
```

主要参数：

参数	说明
`--bed`	merged DEL BED 文件。
`--maf_dir`	single-coverage MAF 目录。
`--target` / `--refname`	reference ID。
`--query_list` / `--glist`	query 列表；VCF 样本顺序按该文件。
`--out`	输出前缀。
`--threads` / `--t`	并行 query 数。
`--maf_suffix`	MAF 后缀，默认常为 `.sing.maf`。
`--min_cov`	参考覆盖判定的最小覆盖比例。
`--min_support`	ALT 支持最小比例。
`--bridge_del_ratio`	bridge alignment 判定 deletion 的比例阈值。
`--bridge_ref_low`	bridge reference coverage 下界。
`--bridge_ref_high`	bridge reference coverage 上界。
`--vcf_mode`	VCF 输出模式。
`--haploid` / `--diploid`	输出单倍体或二倍体 genotype。
`--keep_tmp`	保留中间 per-sample 文件。

1.6.7 Step 07：07_genotype_INS.pl

功能：对 merged insertions 进行 genotyping。支持长插入序列抽样匹配、flank 匹配和 VCF 输出。

常用命令：

```
perl 07_genotype_INS.pl \
  --bed ../SVGAP_run/05_combined_sv/All.INTs.50bplarge.bed.combined.sorted.txt \
  --maf_dir ../SVGAP_run/03_filter_forward/filtered_sing \
  --genome_dir ../genomes \
  --refname ISO1 \
  --query_list ../SVGAP_run/query.list \
```

```
  --out ../SVGAP_run/06_genotype/INS.large \
  --threads 12
```

主要参数:

参数	说明
--bed	merged INS BED 文件。
--maf_dir	single-coverage MAF 目录。
--genome_dir	query/reference FASTA 目录，用于插入序列提取/验证。
--target / --refname	reference ID。
--query_list	query 列表。
--out	输出前缀。
--threads / --t	并行 query 数。
--maf_suffix	MAF 文件后缀。
--pos_tol	插入位置容忍 bp。
--seq_id	序列 identity 阈值。
--flank	flank 匹配长度。
--len_ratio_min	ALT 长度比例下限。
--len_ratio_max	ALT 长度比例上限。
--len_slop	长度绝对容忍 bp。
--min_refcov	reference coverage 判定阈值。
--block_extra	MAF block 扩展搜索长度。
--short_ref_len	短 reference anchor 长度阈值。
--long_seq_len	长插入序列阈值。
--sample_len	长序列抽样窗口长度。
--sample_seed_len	抽样 seed 长度。
--sample_min_hits	seed 最小命中数。
--sample_windows	抽样窗口数量。
--vcf_mode	VCF 输出模式。
--haploid / --diploid	genotype ploidy。
--bed_one_based	输入 BED 是否为 1-based。
--alt_is_insseq	ALT 是否为插入序列本身。
--keep_tmp	保留临时文件。

1.6.8 Step 08：08_genotype_small_indels.pl

功能: 对 1-50 bp small insertions/deletions 进行 genotyping。该脚本可同时读取 small DEL 和 small INS 文件。

常用命令:

```
perl 08_genotype_small_indels.pl \
  --maf_dir ../SVGAP_run/03_filter_forward/filtered_sing \
  --refname ISO1 \
  --query_list ../SVGAP_run/query.list \
  --del_bed ../SVGAP_run/05_combined_sv/All.DELs.50bpsmall.bed.combined.sorted.txt \
  --ins_bed ../SVGAP_run/05_combined_sv/All.INTs.50bpsmall.bed.combined.sorted.txt \
  --out ../SVGAP_run/06_genotype/smallIndel \
  --threads 12
```

主要参数:

参数	说明
--maf_dir	single-coverage MAF 目录。
--target / --refname	reference ID。
--bed / --variants	mixed small InDel BED 文件。
--del_bed	small deletion BED 文件。

参数	说明
--ins_bed	small insertion BED 文件。
--out	输出前缀，默认 small_indel_genotype。
--max_len	最大 indel 长度，默认 50。
--min_len	最小 indel 长度，默认 1。
--maf_suffix	MAF 后缀，默认 .sing.maf。
--query_list / --glist	query 列表。
--other_gt	非 reference/alternative allele 的 GT，默认 ./.。
--use_block_gap / --no-use_block_gap	是否用相邻 MAF block gap 推断 genotype，默认开启。
--max_junction_gap	junction gap 最大长度，默认 1000。
--threads / --p	并行 query 数。
--keep_tmp	保留临时 per-sample 文件。
--bed_coord	输入坐标系统：0 表示 MAF/BED 0-based，1 表示 1-based。
--gt_pos_slop	relaxed genotyping 的位置容忍度，默认 5。
--len_slop	relaxed 模式长度容忍度，默认 0。
--relaxed_gt / --no-relaxed_gt	是否启用 nearby-gap 搜索，默认开启。

1.6.9 Step 09：09_SNPgenotyping.pl

功能：从 single-coverage MAF 中检测 SNP，并把所有 query 的 SNP 位点整合成统一 population VCF。

常用命令：

```
perl 09_SNPgenotyping.pl \
  --singmaf ../SVGAP_run/03_filter_forward/filtered_sing \
  --refsize ../genomes/ISO1.sizes \
  --refname ISO1 \
  --query_list ../SVGAP_run/query.list \
  --speciesname ISO1_A3_A4_A5 \
  --outdir ../SVGAP_run/07_snp \
  --threads 12
```

主要参数：

参数	说明
--singmaf	single-coverage MAF 目录或文件。
--refsize	reference chromosome sizes 文件。
--refseq	兼容旧参数，新版通常不需要。
--refname / --target	reference ID。
--query_list / --glist	query 列表，控制 VCF 样本顺序。
--speciesname	VCF header 中的物种/项目名。
--outdir	输出目录。
--t / --threads	并行任务数。
--tmpdir	临时目录。
--keep_tmp	保留临时文件。
--allow_ambiguous	是否允许 ambiguous bases。
--minNS	N/ambiguous 过滤阈值。
--phased	输出 phased genotype。
--legacy_format	使用旧格式。
--force	覆盖已有输出。

1.6.10 Step 10：10_SVannotation.pl

功能：对 SV VCF 做注释，包括 tandem duplication、TE overlap、CDS overlap 等。DEL 为 symbolic allele 时，会根据 reference 坐标提取序列。

常用命令:

```
perl 10_SVannotation.pl \
  --ref ../genomes/ISO1.fa \
  --vcf ../SVGAP_run/08_vcf/All.largeSV.raw.vcf \
  --te ../annotation/TE.bed \
  --cds ../annotation/CDS.bed \
  --out ../SVGAP_run/08_vcf/All.largeSV.annotated.vcf \
  --workdir ../SVGAP_run/09_annotation \
  --threads 12 \
  --minimap2 minimap2
```

如果系统没有 `minimap2`，可以先跳过 annotation：

```
--skip_annotation
```

或者跳过 tandem duplication 检测：

```
--skip_tandem_dup
```

主要参数:

参数	说明
`--ref`	reference FASTA。
`--vcf`	待注释 VCF。
`--te`	TE annotation BED/GFF。
`--cds`	CDS annotation BED/GFF。
`--out`	输出 VCF。
`--svtype`	只注释某类 SV。
`--workdir`	工作目录。
`--threads` / `--t`	并行线程数。
`--minimap2`	minimap2 程序路径。
`--kmer`	tandem duplication seed k-mer 大小。
`--dup_seed_fraction`	tandem duplication seed 命中比例阈值。
`--skip_tandem_dup`	跳过 tandem duplication 判断。
`--min_annot_pct`	TE/CDS overlap 最小百分比。
`--min_aln_len`	minimap2 比对最小长度。
`--min_mapq`	minimap2 最小 MAPQ。
`--max_dup_flank`	tandem duplication flank 最大长度。
`--max_dup_seeds`	tandem duplication seed 最大数量。
`--max_seq_len`	用于注释的最大序列长度。
`--te_preset`	TE 注释输入 preset。
`--cds_preset`	CDS 注释输入 preset。
`--keep_tmp`	保留临时文件。
`--quiet`	减少输出。

1.6.11 Step 11：11_INVgenotyping.pl

功能：对 merged inversion 候选进行 genotyping，结合 MAF body coverage 和 flank coverage 判断样本是否携带 inversion。

常用命令:

```
perl 11_INVgenotyping.pl \
  --inv ../SVGAP_run/05_combined_sv/All.INVs.bed.combined.sorted.txt \
  --maf_dir ../SVGAP_run/03_filter_forward/filtered_sing \
  --refsize ../genomes/ISO1.sizes \
  --refname ISO1 \
  --speciesname ISO1_A3_A4_A5 \
  --query_list ../SVGAP_run/query.list \
```

```
  --out ../SVGAP_run/06_genotype/INV.vcf \
  --threads 12
```

主要参数:

参数	说明
`--inv`	inversion BED 文件。
`--maf_dir`	single-coverage MAF 目录。
`--sing` / `--singmaf`	单个或目录形式的 sing MAF 输入。
`--refsize`	reference sizes 文件。
`--refname` / `--target`	reference ID。
`--speciesname`	VCF header 项目名。
`--query_list` / `--glist`	query 列表。
`--out`	输出 VCF 文件。
`--outdir`	输出目录。
`--maf_suffix`	MAF 后缀。
`--threads` / `--t`	并行 query 数。
`--bed_coord`	BED 坐标系统。
`--flank_ratio`	flank 长度相对 inversion 长度比例。
`--min_flank`	最小 flank 长度。
`--max_flank`	最大 flank 长度。
`--min_body_cov`	inversion body 最小覆盖比例。
`--min_flank_cov`	flank 最小覆盖比例。
`--dominant_frac`	dominant orientation 最小比例。
`--min_body_bp`	body 最小覆盖 bp。
`--trust_carriers`	信任候选携带样本。
`--body_only`	只根据 body 进行判定。
`--phased`	输出 phased genotype。
`--keep_tmp`	保留临时文件。
`--debug`	输出 debug 信息。

1.6.12 Step 12：12_combine_genotype_CXSV.pl

功能: 合并和 genotyping complex SV。适合处理 reference 与 query gap 同时存在、简单 DEL/INS 无法准确表达的复杂变异。

常用命令:

```
perl 12_combine_genotype_CXSV.pl \
  --refname IS01 \
  --query_list ../SVGAP_run/query.list \
  --rawsv_dir ../SVGAP_run/04_pairwise_sv \
  --outdir ../SVGAP_run/06_genotype/CXSV \
  --break_tolerance 2000 \
  --min_ro 0.50 \
  --len_ratio 1.00
```

主要参数:

参数	说明
`--refname`	reference ID。
`--glist`	genome list。
`--query_list`	query list，优先控制样本顺序。
`--rawsv_dir` / `--svdir`	Step 04 raw SV 目录。
`--outdir`	输出目录。
`--break_tolerance`	断点合并容忍度，默认 2000。
`--min_ro`	最小 reciprocal overlap，默认 0.50。

参数	说明
--len_ratio	最大相对长度差异，默认 1.00。
--min_component_size	complex event 最小组成片段数。
--unknown_missing	非携带样本输出 ./. 而不是 0|0。
--keep_ref_sample	VCF 中保留 reference sample。
--max_info_source_ids	INFO 中最多保留的 source ID 数。

1.6.13 SVGAP_pipeline.pl 主控脚本参数

参数	说明
--refname / --target	reference genome ID，必须出现在 g.list 中。
--glist	genome list；VCF 样本顺序等于去掉 reference 后的顺序。
--genome_dir / --gd	genome FASTA 目录。
--start_from	起点：align、maf、axt，默认 align。
--align_dir / --input	aligner 原始输出目录。
--aligner / --ali	aligner 类型：minimap2、last、lastz、mummer、anchorwave、maf。
--maf_dir	forward MAF 目录。
--maf_reciprocal_dir	独立 reciprocal MAF 目录。
--axt_dir / --ad	forward AXT 目录。
--axt_forward_dir	forward AXT 目录。
--axt_reciprocal_dir	独立 reciprocal AXT 目录。
--reciprocal_strategy	auto、qnet、true、both。默认 auto。
--outdir	主输出目录，默认 SVGAP_run。
--threads / --t	线程/并行任务数。
--speciesname	VCF header 项目名。
--ucsc	UCSC 工具路径。
--tba	TBA 工具路径。
--k8	k8 路径。
--paftools	paftools.js 路径。
--mum320	MUMmer/delta2maf 路径。
--linearGap / --lg	chainNet linearGap 文件。
--refsize	reference sizes 文件。
--te	TE annotation 文件。
--cds	CDS annotation 文件。
--minimap2	minimap2 路径。
--annotation / --no-annotation	是否进行 annotation。
--skip_convert	跳过 01 转换。
--skip_chainnet	跳过 02。
--skip_filter	跳过 03。
--skip_pairwise_sv	跳过 04。
--skip_combine	跳过 05。
--skip_genotype	跳过 06/07/08/11。
--skip_cxsv	跳过 12。
--skip_snp	跳过 09。
--skip_annotation	跳过 10。
--cxsv_break_tolerance	CXSV 断点合并容忍度。
--cxsv_min_ro	CXSV 最小 reciprocal overlap。
--cxsv_len_ratio	CXSV 长度比例阈值。
--cxsv_unknown_missing	CXSV 非携带样本输出 missing。
--dry_run	只打印命令。
--force	覆盖已有输出。

1.6.14 SVGAP_vcf_tools.pl

功能：合并多个 VCF，并强制样本列顺序与 query.list 或 g.list 一致。

```
perl SVGAP_vcf_tools.pl \
  --mode merge \
  --vcfs DEL.vcf,INS.vcf,INV.vcf \
  --query_list query.list \
  --refname ISO1 \
  --refsize ../genomes/ISO1.sizes \
  --out All.largeSV.raw.vcf
```

参数	说明
--mode	当前主要为 merge。
--vcfs	逗号分隔的 VCF 文件。
--out	输出 VCF。
--query_list / --glist	样本顺序文件。
--refname / --target	reference ID。
--refsize	chromosome size 文件，用于排序。
--missing_gt	缺失 genotype，默认 ./.。

1.7 7. 结果检查建议

运行完成后，建议检查：

```
ls -lh SVGAP_run/08_vcf/
less SVGAP_run/SVGAP_pipeline.log
```

检查 VCF 样本列：

```
grep '^#CHROM' SVGAP_run/08_vcf/All.largeSV.raw.vcf
```

应该看到：

```
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT A3 A4 A5
```

统计每类变异数量：

```
grep -v '^#' SVGAP_run/08_vcf/All.largeSV.raw.vcf | wc -l
grep -v '^#' SVGAP_run/08_vcf/All.smallIndel.vcf | wc -l
grep -v '^#' SVGAP_run/08_vcf/All.sorted.SNP.vcf | wc -l
grep -v '^#' SVGAP_run/08_vcf/All.CXSV.vcf | wc -l
```

1.8 8. 常见问题

1.8.1 8.1 仍然出现 Parallel::ForkManager warning

先确认你运行的是清洁版包中的脚本，而不是旧目录中的脚本：

```
which perl
pwd
head -5 SVGAP_pipeline.pl
```

脚本头部应出现：

```
# Author: Yi Liao @ scau.edu.cn
```

并且包含：

```
use lib "$Bin/lib";
```

再检查：

```
perl -Ilib -MParallel::ForkManager -e 'print "OK\n"'
```

如果这个命令成功，但流程仍有 warning，通常说明你调用的是旧脚本路径。

1.8.2 8.2 AXT 文件找不到

AXT 必须非空，并且命名为：

```
ISO1vsA3.axt
ISO1vsA4.axt
ISO1vsA5.axt
```

大小为 0 的空文件会被跳过。

1.8.3 8.3 genome FASTA 找不到

确认 `g.list` 中 ID 与 FASTA 文件名前缀一致。例如 `A3` 必须对应：

```
A3
A3.fa
A3.fasta
A3.fna
```

1.8.4 8.4 minimap2 缺失

主流程检测 SV/SNP/InDel 不一定需要系统有 `minimap2`，但 annotation 中 tandem duplication 检查会用到。若没有 minimap2，可先加：

```
--skip_annotation
```

或在单独运行 `10_SVannotation.pl` 时加：

```
--skip_tandem_dup
```

1.8.5 8.5 内存和线程

`--threads` 越大，并行 query 越多，速度越快，但内存也会增加。对于 3 个 query，如 A3/A4/A5，`--threads 3` 到 `--threads 12` 都可以；如果单个 genome 很大，建议先用 `--threads 4` 或 `--threads 6` 测试。

1.8.6 8.6 qnet 和 reciprocal 怎么选

没有真正独立的 query-vs-reference alignment 时，使用默认 `auto` 即可，流程会使用 forward chainNet 的 `qnet` 恢复 reference insertion 信息。如果你确实独立跑了 `A3vsISO1.axt`、`A4vsISO1.axt`、`A5vsISO1.axt`，可以使用 `--reciprocal_strategy true`。

1.9 9. 培训演示建议流程

培训时推荐按以下顺序讲解：

1. 展示 `g.list` 和 genome FASTA 命名。
2. 展示 AXT 命名规则 `ISO1vsA3.axt`。
3. 用 `--dry_run` 运行主控脚本，让学员看到每一步命令。
4. 正式运行时先加 `--skip_annotation`。
5. 运行完成后重点讲 `08_vcf/` 中的四类输出：large SV、small InDel、SNP、CXSV。
6. 解释 `query.list` 如何控制 VCF 样本列顺序。
7. 最后再单独演示 annotation 和 benchmark 工具。

`--dry_run` 示例：

```
perl SVGAP_pipeline.pl \
  --refname ISO1 \
  --glist ../g.list \
  --genome_dir ../genomes \
```

```
--start_from axt \
--axt_dir ../01_axt/Target \
--outdir ../SVGAP_run_dryrun \
--threads 12 \
--skip_annotation \
--dry_run
```